Programmazione di
Applicazioni Data Intensive
Introduzione

Laurea in Ingegneria e Scienze Informatiche
DISI – Università di Bologna, Cesena

G. Domeniconi, G. Moro, R. Pasolini
DISI Università di Bologna, Cesena
name.surname@unibo.it

Definizione

- Si definiscono ***data intensive*** le applicazioni in cui la gestione ed elaborazione dei dati costituiscono l'aspetto di maggiore importanza e complessità
  - usato anche in contrapposizione a *compute intensive*, riferito ad applicazioni maggiormente basate su elevate capacità computazionali
- *"We call an application* data-intensive *if data is its primary challenge: the quantity of data, the complexity of data, or the speed at which it is changing."*

  M. Kleppmann, "Designing Data-Intensive Applications" (2014)

Motivazioni: Crescente Quantità di Dati

- I dati sono prodotti costantemente e in grandi quantità
  - La crescita del World Wide Web ha portato ad avere una enorme quantità di informazione disponibile pubblicamente
- Questi dati sono prodotti in varie forme, strutturate (dati numerici, serie temporali, ...) e non (testi, immagini, ...)
- *"In 2006, the amount of digital information created, captured, and replicated was 1,288 x 10^{18} bits. In computer parlance, that's 161 exabytes or 161 billion gigabytes. This is about 3 million times the information in all the books ever written."*

  D. Reinsel et al., "The Expanding Digital Universe", IDC white paper (2007)
- *"We must harness the Internet's energy before the information it has unleashed buries us."*

  V. G. Cerf, "An Information Avalanche" (2007)

Problematiche

Raccolta

- Gestire nuovi dati generati in continuazione

Memorizzazione

- Archiviazione efficiente in termini di spazio e di tempo

Ricerca

- Reperimento efficiente dei dati d'interesse
- Sintesi dei dati (medie, totali, …) per migliore fruibilità

Analisi

- Estrazione efficiente di conoscenza utile economicamente
- Possibilità di aggiornare la conoscenza incrementalmente
- Elaborazioni distribuite di dati sparsi su molteplici nodi

Progettazione

- Progettazione *Model-driven* di applicazioni UI *platform-independent*
  - Es: web application, mobile, desktop, ecc…

Tecnologie

- I mezzi tecnologici disponibili per la trattazione dei dati sono in costante sviluppo e sempre più accessibili
- Infrastrutture scalabili per l'elaborazione parallela e distribuita dei dati sono ormai ampiamente diffuse
  - anche in forma di servizi offerti da terze parti (*Infrastructure as a Service*, vedi ad es. Amazon Web Services)
- Diversi progetti di software libero e open source hanno raggiunto livelli di maturità tali da essere preferibili a costose soluzioni commerciali
- È possibile dalle proprie applicazioni reperire informazioni e dati da social network attraverso API
  - Es: twitter, facebook, LinkedIn….

Tipologia prodotti software forniti dalle imprese ICT

- Numero di imprese ICT con relativi prodotti software nella provincia di Forlì-Cesena
- Le aziende di software che fanno siti web sono le più numerose
  - Più di quelle che fanno sistemi informativi o applicazioni mobile

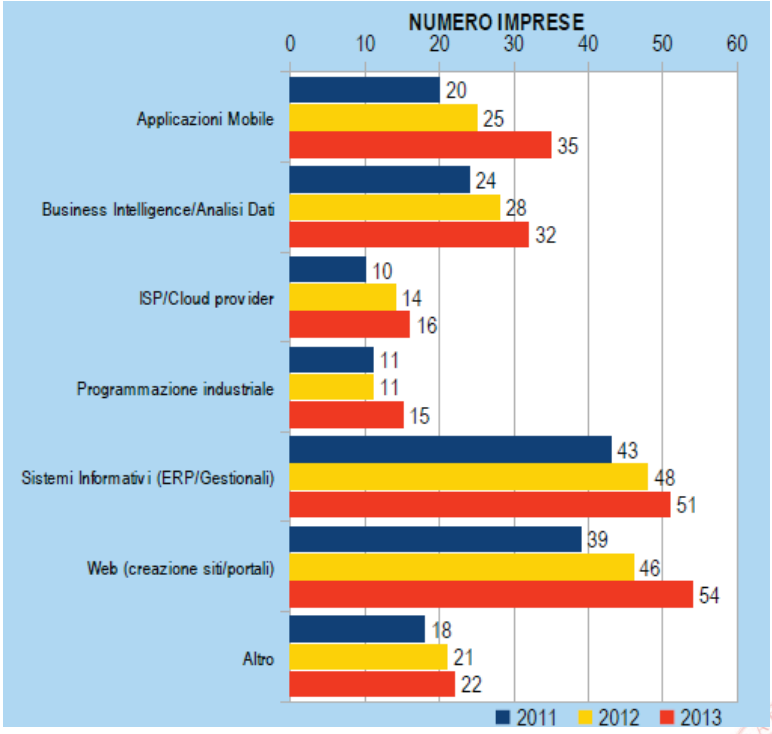

Caso di studio

- Come caso di studio concreto per il corso è la realizzazione di un semplice **sito di e-commerce** e l'analisi dei dati raccolti dalle attività dei suoi utenti

Caso di studio: motivazioni

Un sito di e-commerce rappresenta un caso di studio esaustivo di applicazione data intensive

- I più grandi portali di e-commerce (es. Amazon) con cataloghi di milioni di prodotti necessitano di sistemi estremamente ottimizzati per la memorizzazione e la ricerca dei dati, in grado di gestire richieste di migliaia di utenti allo stesso tempo
- Gli ordini eseguiti dai clienti e i voti che danno ai prodotti costituiscono una grande mole di informazione strutturata, analizzabile in modo efficiente per fornire suggerimenti di acquisto, sia generali che personalizzati sui singoli clienti
- Dalle recensioni testuali dei clienti può essere stimato il loro grado di soddisfazione verso i singoli prodotti e si può valutare la reputazione dei rispettivi marchi

Caso di studio: requisiti

- Il sito presenta un catalogo di prodotti, organizzati in una gerarchia di categorie
- Gli utenti del sito devono essere in grado di autenticarsi con i loro rispettivi account
- Ogni utente può raccogliere prodotti in un carrello per poi compiere l'ordine di questi prodotti
- L'utente può consultare gli ordini fatti in passato
- Ogni prodotto è corredato da recensioni, compilate dagli utenti che lo hanno acquistato in passato
  - Ogni recensione corrisponde ad uno specifico acquisto del prodotto
  - Ogni recensione è costituita da un punteggio (1-5 stelle) e del testo

Caso di studio: dati di esempio

- Per ottenere un esempio realistico di applicazione, forniamo un database prepopolato con un set di dati di esempio estratti da Amazon.com (versione USA di Amazon)
- La quantità di dati è relativamente contenuta rispetto ai casi reali più *data intensive*, in modo da rendere più rapide le attività di laboratorio che prevedono l'analisi dell'intero set
  - 11.000 prodotti organizzati in decine di categorie
  - 11.000 utenti, esecutori di 100.000 ordini e autori di 500.000 recensioni
- Le tecnologie che presentiamo sono ad ogni modo scalabili, usate nella realtà anche per moli di dati molto più grandi

Caso di studio: dati analizzabili

- Lo storico degli acquisti degli utenti e le loro recensioni costituiscono una mole potenzialmente enorme di dati
- Questi dati possono essere analizzati per estrarre informazioni utili e fornire un migliore servizio ai clienti e ai venditori
- Agli utenti, possono essere messi in evidenza i prodotti a cui potrebbero essere maggiormente interessati (***recommendation***)
- Dalle recensioni di ciascun prodotto (potenzialmente migliaia), è possibile estrarre informazioni sommarie sull'opinione generale degli acquirenti nei suoi confronti (***customer satisfaction***)

Caso di studio: componenti

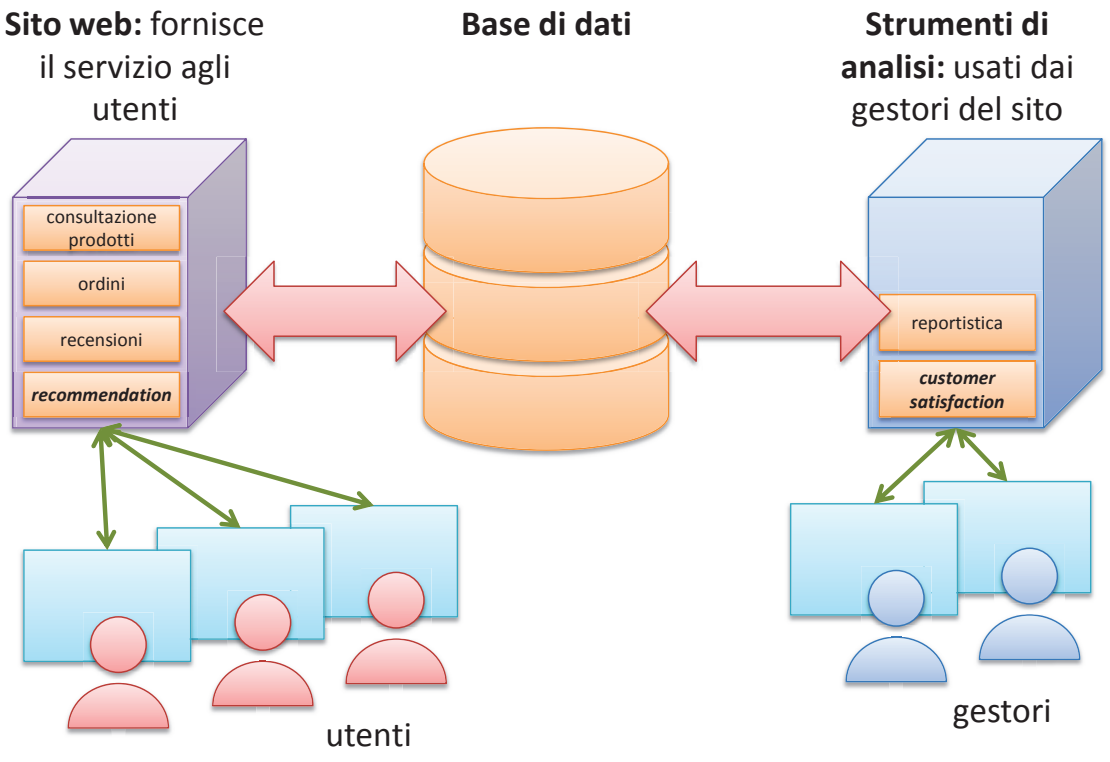

Caso di studio: realizzazione

- Durante il corso saranno presentati due approcci differenti per la realizzazione dell'applicazione presentata
- Dapprima vediamo lo sviluppo *model-driven*, in cui dal modello costruito in fase di progettazione viene generato automaticamente il codice dell'applicazione
- Dopo implementeremo manualmente l'applicazione, vedendo nel dettaglio le tecnologie di base usate per la realizzazione, le problematiche ricorrenti e le soluzioni ad esse
- In seguito presenteremo ulteriori tecnologie usate per l'analisi dei dati e l'estrazione di informazione, che useremo per aggiungere funzionalità avanzate all'applicazione

IFML

- *Interaction Flow Modeling Language* (IFML) è un linguaggio visuale standard per la modellazione di applicazioni
  - È un'evoluzione di WebML, linguaggio di modellazione sviluppato appositamente per applicazioni Web data intensive
- Il modello IFML descrive le interazioni dell'utente col front-end dell'applicazione (*User Interactions*)
  - Sono definite le viste che compongono l'interfaccia (*Container*), gli elementi contenuti (*Component*), i collegamenti tra loro (*Navigation* e *Data Flow*), le possibili interazioni (*Event*) e i loro effetti (*Action*)
- Il modello è indipendente dalla piattaforma di esecuzione e non impone requisiti sul layout e sullo stile del front-end
  - IFML può descrivere applicazioni che girano su molteplici piattaforme differenti: Web, mobile, desktop ecc.

Creazione di una applicazione UI

Modello Dati + Modello Interazioni + Modello Presentazione

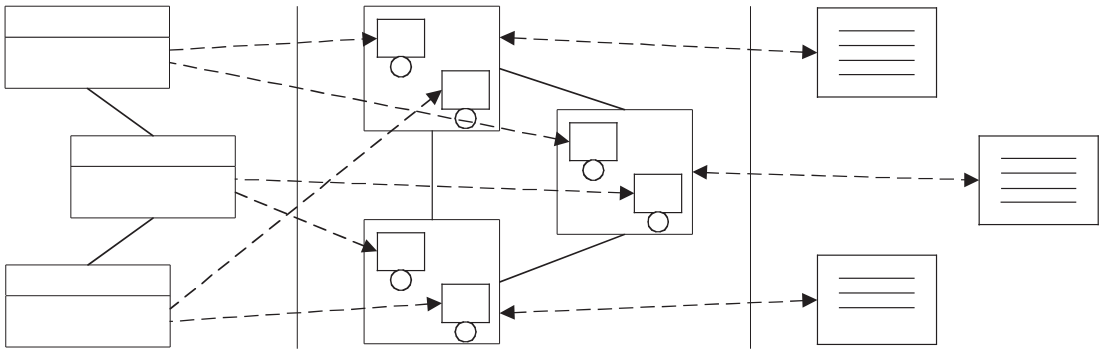

Struttura del contenuto (entità, relazioni)

Struttura dell'applicazione (unità, pagine, link, site view)

Presentazione (stili)

WebRatio

- WebRatio è un ambiente basato su Eclipse per lo sviluppo *model-driven* di applicazioni basato su diversi linguaggi
  - ER (*Entity/Relationship*) per il modello dei dati del dominio
  - IFML per la definizione delle User Interaction
  - BPMN (*Business Process Model and Notation*) per la definizione dei processi di business tramite diagrammi di flusso
- WebRatio consente lo sviluppo agile e rapido di un'applicazione Web, in modo completamente visuale
- Dal progetto sono generati in automatico lo schema del DB e l'implementazione basata su Java EE dell'intera applicazione
  - È possibile definire stili di presentazione e componenti personalizzati
- WebRatio sarà usato per costruire interamente l'applicazione

IFML: Progettazione Model-driven platform-independent

- Al giorno d'oggi tutti i più grandi e-store permettono la navigazione e l'utilizzo sia da web app che da mobile
- Con IFML e WebRatio è possibile modellare la parte UI indipendentemente dalla piattaforma di destinazione e generare automaticamente il codice relativo all'app desiderata

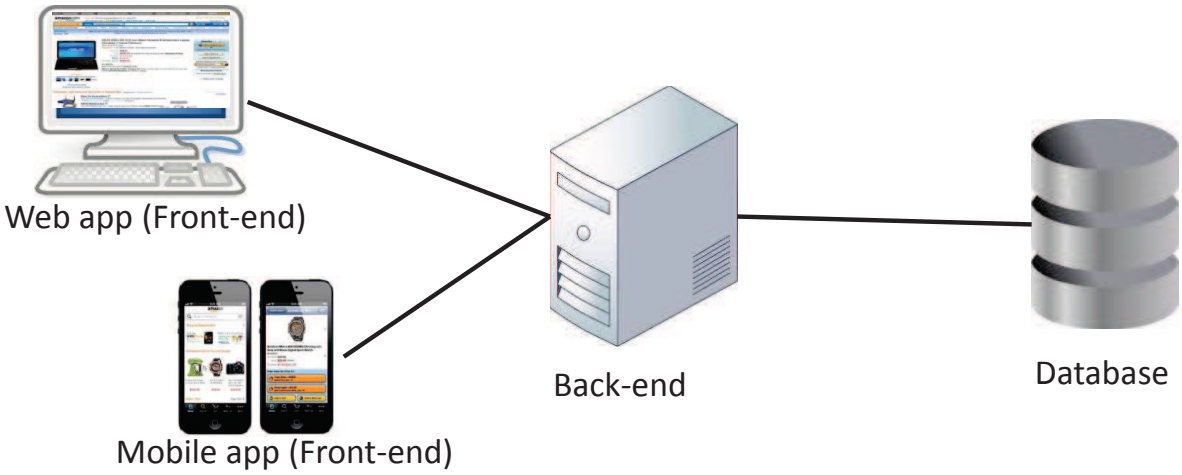

Database Relazionali

- I database basati sul modello relazionale costituiscono l'approccio più comune alla memorizzazione di grandi masse di dati con frequenti operazioni di lettura e scrittura
- Uno dei RDBMS più usati è PostgreSQL: software libero aderente allo standard SQL e con funzionalità avanzate
- L'uso di un database relazionale richiede la definizione di uno schema dei dati
  - Dei vincoli devono essere definiti per garantire la correttezza dei dati
  - L'uso di opportuni indici è fondamentale per l'efficienza
- JDBC è l'interfaccia standard di Java per l'accesso ai RDBMS
- Vedremo come si costruirebbe da zero lo schema del database usato nell'applicazione, completo di vincoli e indici

Applicazioni Web

- I servizi fruibili via Web (social network, e-commerce ecc.) sono tra gli esempi più comuni di applicazioni data intensive
  - Usate da molteplici utenti contemporaneamente, che consumano e producono dati in continuazione
- Diverse applicazioni Web sono basate sulla piattaforma Java
  - in particolare applicazioni con forti requisiti di affidabilità ed efficienza
- Vedremo le tecnologie di base per le applicazioni Web in Java
  - servlet per la logica applicativa (*controller*)
  - JSP per la creazione dinamica di pagine Web (*view*)
- Queste saranno utilizzate per la costruzione dell'applicazione di e-commerce presentata come caso di studio

Object-Relational Impedance Mismatch

- L'uso di un database relazionale per la persistenza di dati di un'applicazione object-oriented comporta problemi dati dalla discrepanza tra i due paradigmi, detta *impedance mismatch*
- Nel paradigma object-oriented abbiamo oggetti identificati dalla loro posizione in memoria, spesso composti da altri oggetti (collegati tramite puntatori) accessibili tramite metodi
- Nel database relazionale, i dati corrispondenti ad un oggetto composto sono distribuiti su diverse tabelle, identificati e riferiti tramite chiavi: sono necessari join tra tabelle
- La conversione dei dati tra i due modelli richiede soluzioni non banali da progettare

Esempio: Ordine ad Oggetti e su Database Relazionale

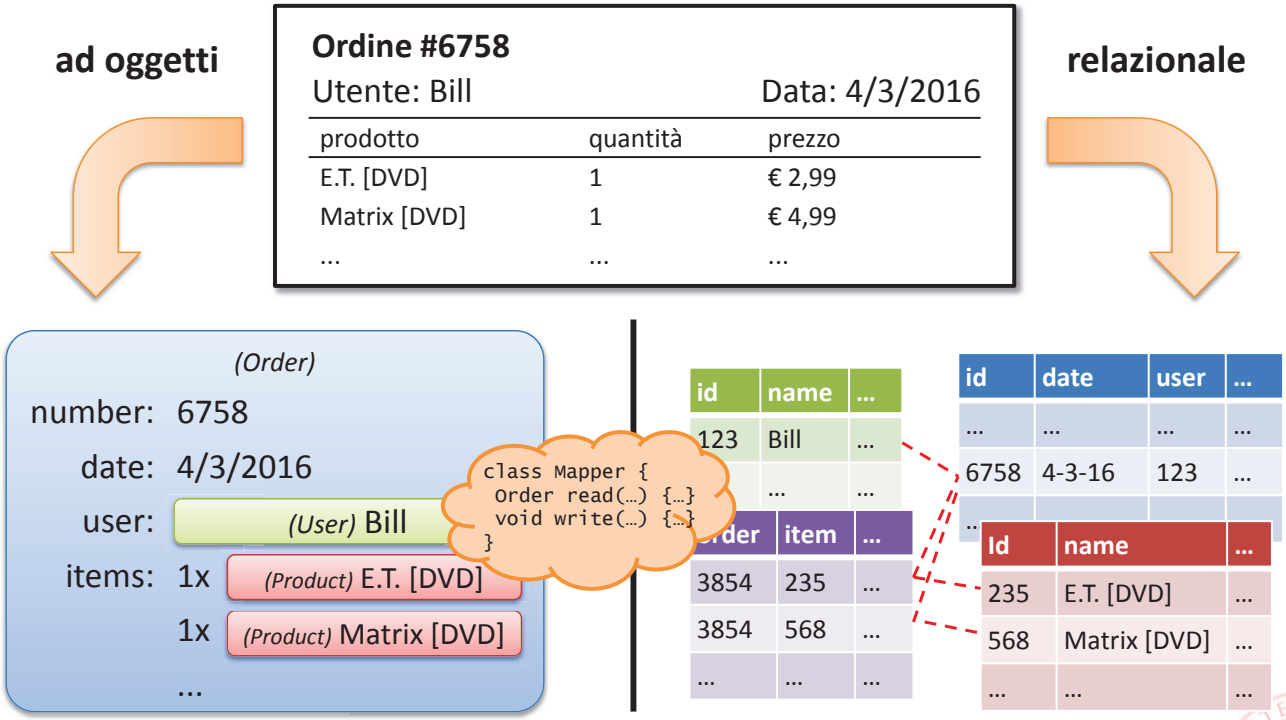

Object-Relational Mapping

- Con *object-relational mapping* ci si riferisce alle soluzioni a livello di progetto e implementazione adottate per risolvere l'impedance mismatch, per cui esistono diversi approcci
  - Devono permettere di leggere e scrivere oggetti persistenti sul DB, garantendo consistenza, accessi concorrenti tramite transazioni ecc.
- Le soluzioni basate su *Data Access Object* prevedono la creazione di uno strato dell'applicazione che incapsuli la logica di accesso al database e la separi dal resto dell'applicazione
- Vedremo in primo luogo come realizzare uno strato DAO per la nostra applicazione basato su JDBC
- Si vedrà che l'implementazione dei DAO richiede di scrivere grandi quantità di codice: non è l'approccio più conveniente

Framework per la Persistenza

- I framework di persistenza forniscono un'implementazione dei meccanismi tipici di object-relational mapping, riducendo notevolmente il carico di lavoro degli sviluppatori
- Una volta configurato correttamente in base alle esigenze e al modello dei dati della propria applicazione, un framework offre un API di alto livello per gestire oggetti persistenti su DB
- Come software di riferimento useremo Hibernate, un framework di persistenza open source ampiamente diffuso
- Vedremo come sia possibile sostituire il DAO basato su JDBC con uno basato su Hibernate, più rapido da implementare
  - Vedremo nel dettaglio la dichiarazione del mapping tra classi Java e tabelle del DB e l'uso delle API per la gestione ai dati persistenti

Suggerimenti di Acquisto **Impersonali**: Regole Associative

- I dati raccolti da un'applicazione data intensive possono essere analizzati per estrarre informazioni di alto livello
- Nel caso del sito di e-commerce, possiamo analizzare i dati generati dall'attività degli utenti per suggerire prodotti che possono potenzialmente essere interessati ad acquistare
- Dall'analisi dei prodotti venduti nei singoli ordini, è possibile estrarre regole associative che indichino quali prodotti siano frequentemente venduti insieme ad altri
- Vedremo come realizzare un semplice algoritmo per individuare, per ciascun prodotto, quelli maggiormente correlati ad esso

Suggerimenti di Acquisto **Personali**: Recommendation di Prodotti

- Analizzando le recensioni date dagli utenti, i sistemi di recommendation possono fornire suggerimenti personalizzati per ciascun utente in base ai propri gusti
  - Diversi delle regole associative, che non considerano i singoli utenti
- RecDB è un'estensione integrata in PostgreSQL che consente di ottenere recommendation direttamente dal DB, tramite semplici query SQL con una clausola aggiuntiva
- Apache Mahout è una libreria Java open source che fornisce diversi algoritmi di recommendation configurabili, con varie possibili fonti di dati e funzionalità per valutarne l'accuratezza
- Vedremo come integrare le recommendation nel nostro sito, mostrando suggerimenti precalcolati periodicamente

Full Text Search

- I dati testuali di un'applicazione (descrizioni, recensioni, …) sono *destrutturati*, non sono analizzabili direttamente come i dati strutturati (numeri, date, …) e devono essere invece convertiti in rappresentazioni appropriate
- I sistemi di *Full Text Search* consentono di indicizzare grandi moli di dati testuali ed effettuare in essi ricerche di singole parole, frasi, parole simili ecc.
- Apache Lucene è una libreria Java open source per costruire indici di documenti testuali ed effettuare ricerche su essi
- Hibernate Search è un'estensione di Hibernate che sfrutta Lucene per consentire la Full Text Search sui dati persistenti
- Integreremo Search nella nostra applicazione per consentire la ricerca full text di prodotti e recensioni

Analisi della Customer Satisfaction

- Una volta strutturati, i dati testuali possono essere analizzati per estrarre conoscenza potenzialmente utile
- Dall'analisi delle recensioni scritte dai clienti, è possibile dedurre il loro grado di soddisfazione nei confronti dei prodotti acquistati, etichettandolo come positivo o negativo
- Un possibile approccio consiste nell'individuare parole note a priori che esprimono sentimenti positivi e negativi e valutare ogni recensione in base alla frequenza con cui appaiono
- Un approccio più avanzato è basato sul *machine learning*: un algoritmo di apprendimento analizza recensioni pre-etichettate ed estrae in automatico un modello di conoscenza utilizzabile per dedurre la polarità di altre recensioni

Organizzazione del Corso

Lezioni (secondo semestre)

- 50 ore tra lezioni in aula e esercitazioni in laboratorio

Modalità di esame (6 CFU)

- Prova orale con:
  - Discussione di progetto di laboratorio di gruppo (1-3 studenti) concordato con il docente, su uno o più argomenti del corso, con un argomento per ogni partecipante (gruppo con 3 membri -> 3 argomenti).
  - Domande sul programma del corso

Materiale didattico

- Slide fornite dal docente
- Riferimenti bibliografici (vedi prossime slide)
- Software e set di dati disponibili in laboratorio e scaricabili gratuitamente

Riferimenti (1)

- Introduzione
  - I. Gorton, D. K. Gracio; “Data-Intensive Computing – Architectures, Algorithms and Applications”; Cambridge University Press; 2013
  - M. Kleppmann; “Designing Data-Intensive Applications”; O’Reilly; 2014
- IFML e WebRatio
  - Specifica OMG di IFML: http://www.omg.org/spec/IFML/
  - M. Brambilla, P. Fraternali; “Interaction Flow Modeling Language: Model-Driven UI Engineering of Web and Mobile Apps with IFML”; Morgan Kaufman; 2014. Link: http://www.sciencedirect.com/science/book/9780128001080
  - IFML: http://www.ifml.org/
  - WebRatio: http://www.webratio.com/

Riferimenti (2)

- Database relazionali
  - PostgreSQL: http://www.postgresql.org/
- Sviluppo Java Web
  - Documentazione API di Java EE: https://docs.oracle.com/javaee/7/api/
- Object-Relational Mapping
  - Hibernate: http://hibernate.org/orm/
  - C. Bauer, G. King, G. Gregory; “Java Persistence with Hibernate”; Manning; 2013

Riferimenti (3)

- Recommendation e machine learning
  - F. Ricci, L. Rokach, B. Shapira, P. B. Kantor; “Recommender Systems Handbook”; Springer; 2011
  - RecDB: https://github.com/Sarwat/recdb-postgresql
  - Apache Mahout: http://mahout.apache.org/
  - S. Owen, R. Anil, T. Dunning, E. Friedman; “Mahout in Action”; Manning; 2012
- Full Text Search
  - Apache Lucene: http://lucene.apache.org/core/
  - Hibernate Search: http://hibernate.org/search/